

# Equipe - Classificação de Espécies de Pássaros

## Alunos:

Thayná Ferreira Lopes

Mabyilly Kauany Neres da Silva

# Sumário

---

- Introdução
- Metodologia
  - Dataset
  - Métodos de literatura: InceptionResNetV2
  - Métodos próprio
- Resultados
  - Literatura x Próprios
  - Nossos resultados
- Conclusão
  - Compilado dos resultados
  - Impacto e valor estratégico
  - Visão de futuro e inovação
- Referências

# Introdução

---

- Resumo do problema

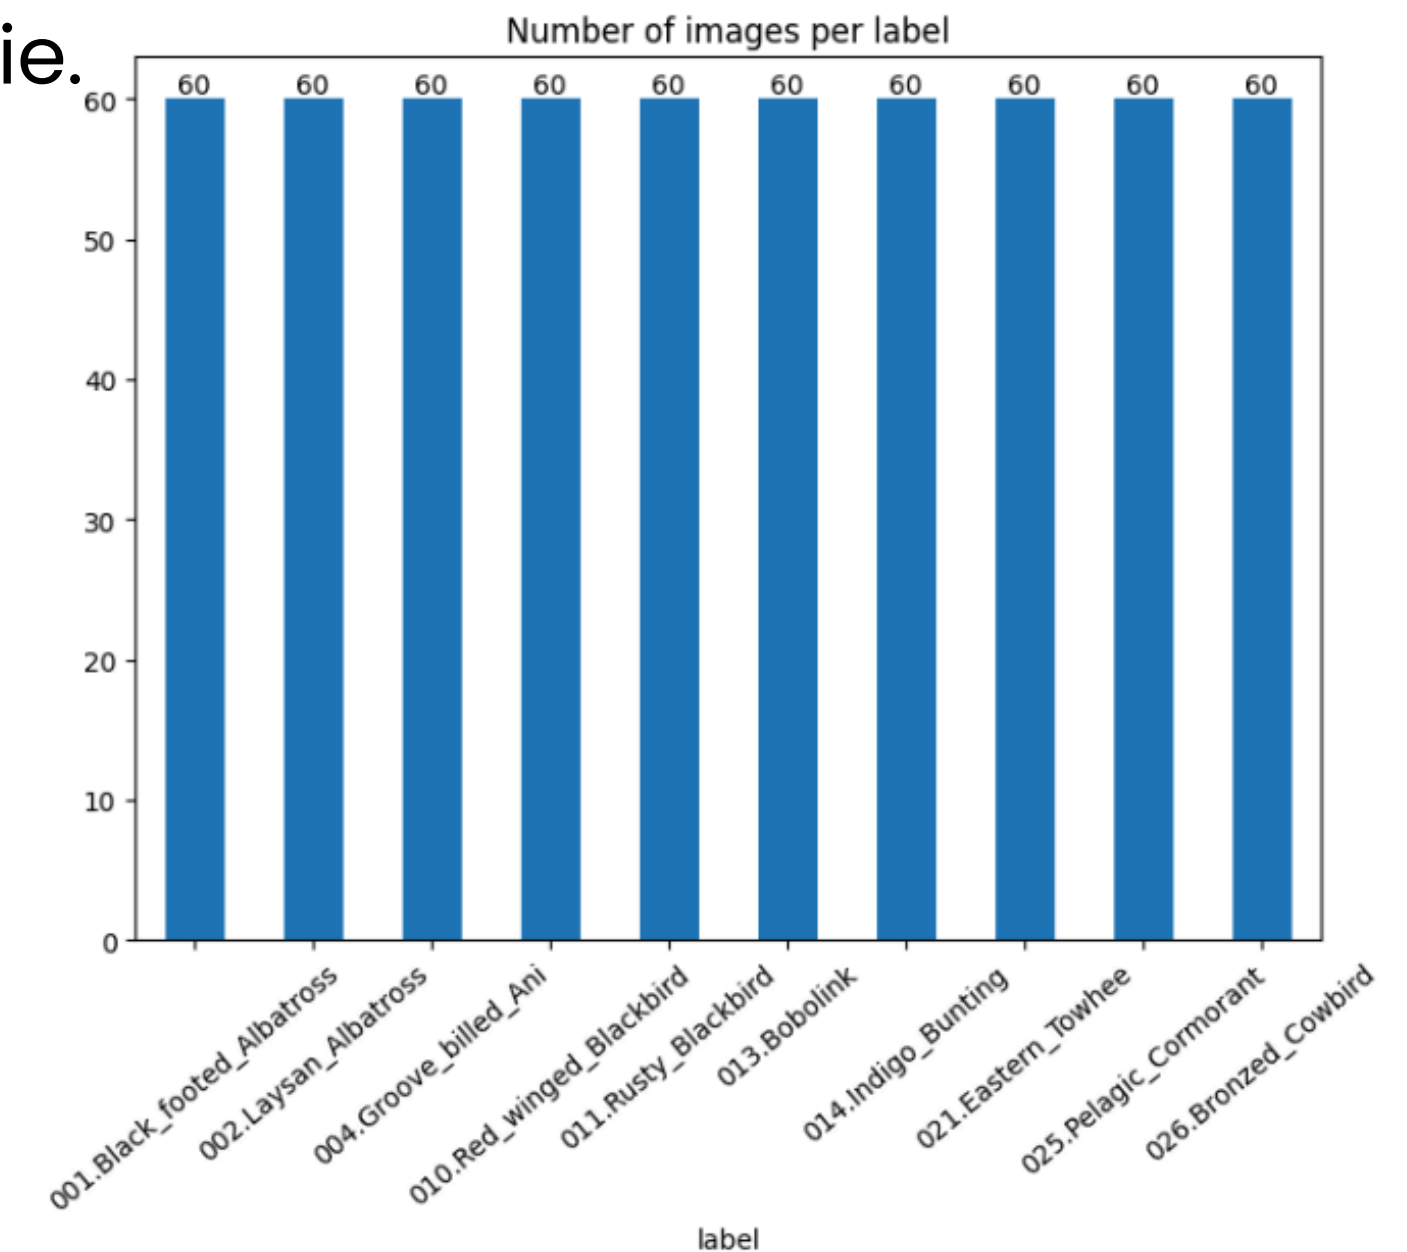
Classificação de imagens para identificar espécies de pássaros.

- Porque esse problema?
  - Desafio de distinguir espécies visualmente semelhantes.
  - Dataset rico para aplicar e comparar técnicas de segmentação.
- Objetivo geral

Comparar a segmentação própria com a segmentação já disponível no dataset  
“200 Bird Species with 11,788 Images”

# Dataset

- Base de dados: 200 Bird Species (11.788 imagens, Kaggle)
  - Seleccionadas 10 classes com 60 imagens cada (600 no total) todas no formato jpg, com exemplo visual por espécie.





# Dataset

- Resultado da análise
  - Todas as imagens com segmentações válidas, labels e split definidos.
  - Nenhuma imagem corrompida e apenas uma duplicada.
  - Estatísticas de altura, largura e canais.

	Largura	Altura	Canal
Média	385.35	469.68	3
Desvio	71.12	61.55	0
Mínimo	136	167	3
Máximo	500	500	3



# InceptionResNetV2

---





- Base: combina as arquiteturas Inception e ResNet, permitindo redes muito profundas sem perda de desempenho.
- Ideia principal: captura padrões em diferentes escalas usando convoluções paralelas e conexões residuais (skip connections).
- Destaque: alcança alta acurácia em tarefas de classificação de imagens em larga escala.
- Motivo da escolha: modelo de referência em transfer learning, ideal para comparar com nosso método mais leve.

# Métodos Próprios

---

- Fine-tuning com InceptionResNetV2
  - Reutilizamos pesos pré-treinados no ImageNet e ajustamos as camadas finais para 10 classes de pássaros.
  - Congelamos as camadas iniciais para reduzir o custo computacional e focar o treino nas últimas camadas.
- Regularização e Data Augmentation
  - Aplicamos Dropout e Weight Decay para evitar overfitting.
  - Usamos Data Augmentation com rotações, ajustes de brilho e recortes (Cutout).
- Otimização de Hiperparâmetros
  - Testamos diferentes learning rates e batch sizes, além de usar o scheduler ReduceLROnPlateau para ajustar a taxa de aprendizado conforme o desempenho.

# Literatura x Próprios




Acuracia literatura: 0.9707  
Loss literatura: 0.1600

Acurácia: 0.7823  
Loss: 0.8479




# Nossos resultados

	precision	recall	f1-score	support
001.Black_footed_Albatross	0.88	0.58	0.70	12
002.Laysan_Albatross	0.69	0.92	0.79	12
004.Groove_billed_Ani	0.67	0.83	0.74	12
010.Red_winged_Blackbird	1.00	1.00	1.00	12
011.Rusty_Blackbird	0.58	0.58	0.58	12
013.Bobolink	0.46	0.50	0.48	12
014.Indigo_Bunting	0.92	1.00	0.96	12
021.Eastern_Towhee	1.00	0.83	0.91	12
025.Pelagic_Cormorant	0.92	0.92	0.92	12
026.Bronzed_Cowbird	0.78	0.58	0.67	12
accuracy			0.78	120
macro avg	0.79	0.78	0.77	120
weighted avg	0.79	0.78	0.77	120




# Nossos resultados


Verdadeiro: 011.Rusty\_Blackbird  
Previsto: 011.Rusty\_Blackbird



Verdadeiro: 025.Pelagic\_Cormorant  
Previsto: 025.Pelagic\_Cormorant



Verdadeiro: 004.Groove\_billed\_Ani  
Previsto: 004.Groove\_billed\_Ani



Verdadeiro: 014.Indigo\_Bunting  
Previsto: 014.Indigo\_Bunting



Verdadeiro: 011.Rusty\_Blackbird  
Previsto: 011.Rusty\_Blackbird



Verdadeiro: 002.Laysan\_Albatross  
Previsto: 002.Laysan\_Albatross



Verdadeiro: 026.Bronzed\_Cowbird  
Previsto: 026.Bronzed\_Cowbird



Verdadeiro: 011.Rusty\_Blackbird  
Previsto: 011.Rusty\_Blackbird



Verdadeiro: 013.Bobolink  
Previsto: 013.Bobolink



# Impacto e Valor Estratégico

---

- Monitoramento Ambiental Inteligente
  - Substituição de inspeções manuais por análise automatizada.
  - Economia de Custos e Redução de Tempo em campo.
- Inventário Rápido em Escala
  - Processamento de milhares de imagens em minutos.
  - Apoio a órgãos governamentais (fiscalização) e empresas (EIA/RIMA).
- Ciência Cidadã e Pesquisa
  - Otimização do trabalho de biólogos (foco em análise complexa).

# Visão de Futuro e Inovação

---

- Robustez
  - Expansão do dataset para maior número de espécies.
- Evolução Tecnológica
  - Implementação de Object Detection (localização do pássaro na imagem).
- Otimização para o Campo
  - Redução do modelo para Edge Computing (drones e câmeras de campo).

# Referências Bibliográficas

---

IKKIOCEAN. Bird Species Classification Using DL. Kaggle Notebook. Disponível em: VEERALAKRISHNA. 200 Bird Species with 11,788 Images [base de dados]. Kaggle, 2025. Disponível em: <https://www.kaggle.com/datasets/veeralakrishna/200-bird-species-with-11788-images/data>. Acesso em: 24 set. 2025.. Acesso em: 07 out. 2025.

VEERALAKRISHNA. 200 Bird Species with 11,788 Images [base de dados]. Kaggle, 2025. Disponível em: <https://www.kaggle.com/datasets/veeralakrishna/200-bird-species-with-11788-images/data>. Acesso em: 24 set. 2025.. Acesso em: 24 set. 2025.